

بهبود امنیت شبکه با استفاده از یادگیری ماشین در سیستم تشخیص نفوذ

الهام حاجیان¹

¹استادیار گروه مهندسی کامپیوتر، دانشگاه بجنورد، e.hajian@ub.ac.ir

* نویسنده مسئول: الهام حاجیان

چکیده

امروزه توسعه روزافزون شبکه‌های رایانه‌ای و کاربرد وسیع آن در زندگی بشر، لزوم تامین امنیت این شبکه‌ها را بیش از پیش نمایان ساخته است. جهت تأمین امنیت از ابزارهای استفاده می‌شود که سیستم تشخیص نفوذ از جمله آنها به شمار می‌رود. سیستم‌های تشخیص نفوذ نقش مهمی در شناسایی و کاهش نقض‌های امنیتی احتمالی در شبکه‌های کامپیوتری دارند. معماری‌های امروزی استفاده شده برای سیستم‌های تشخیص نفوذ، طراحان را در انتخاب نوع معماری کارایی که بتواند قابلیت اطمینان بیشتری در مورد تشخیص حملات داشته باشد با دشواری‌هایی مواجه کرده است و آن‌ها مجبور به استفاده از طرح‌های پیچیده‌ای برای بالا بردن توانایی این سیستم‌ها برای تشخیص تهاجم‌ها و مصون ماندن از حملات صورت گرفته بر علیه آن‌ها شده‌اند. یادگیری ماشین بدلیل آنالیز کردن الگوهای ترافیک شبکه، شناسایی ناهنجاری‌ها نسبت به روش‌های مبتنی بر امضا ارجحیت دارند. همچنین می‌تواند در مجموعه داده‌های بزرگ و شبکه‌های بزرگ یاد بگیرد و دقت بالایی داشته باشد و راحت‌تر می‌تواند با تکنیک‌های حملات جدید خود را منطبق کند.

این پژوهش بر توسعه سیستم تشخیص نفوذ مبتنی بر یادگیری ماشین تمرکز دارد. در این پژوهش، از قدرت الگوریتم‌های یادگیری ماشین برای تجزیه و تحلیل الگوهای ترافیک شبکه و شناسایی تهدیدات امنیتی بالقوه استفاده می‌کند. هدف این پژوهش، ایجاد سیستمی است که بتواند به طور دقیق بین فعالیت‌های عادی شبکه و نفوذهای مخرب تمایز قائل شود. در نهایت، با چندین الگوریتم یادگیری ماشین از جمله K نزدیکترین همسایه، رگرسیون لجستیک و درخت تصمیم مقایسه می‌شود تا موثرترین رویکرد برای تشخیص نفوذ را تعیین کند.

کلمات کلیدی: سیستم تشخیص نفوذ، یادگیری ماشین، رگرسیون لجستیک، درخت تصمیم، k نزدیکترین همسایه

1- مقدمه

با افزایش سرعت، اندازه و تعداد کامپیوترها بعد از سال 1970، اهمیت امنیت سیستم‌های کامپیوتری افزایش یافت و با توجه به افزایش حجم داده‌های ذخیره شده، مرور و تحلیل دستی آنها مشکل گردید. سیستم تشخیص نفوذ یک نرم افزار با قابلیت تشخیص، آشکارسازی و پاسخ (واکنش) به فعالیت‌های غیرمجاز یا ناهنجار در رابطه با سیستم می‌باشد. به عبارت دیگر سیستم تشخیص نفوذ یک سیستم محافظتی است که خرابکاری‌های در حال وقوع در شبکه را شناسایی می‌کند. در این سیستم‌ها با استفاده اطلاعاتی مانند پویس پورت ها و تشخیص ترافیک غیر متعارف، نفوذ خرابکاری‌ها را می‌توان کشف و به مسئول شبکه گزارش داد [1]. سیستم‌های تشخیص نفوذ، اغلب از دو روش تشخیص سوء استفاده و تشخیص ناهنجاری به منظور تشخیص نفوذ استفاده می‌کنند. روشهای تشخیص سوء استفاده، نرخ تشخیص بالایی دارند اما توانایی شناسایی حملات جدید را ندارند. در مقابل، روشهای تشخیص ناهنجاری، توانایی شناسایی حملات جدید را دارند اما نرخ هشدار غلط بالایی دارند. برای آنکه سیستم‌های تشخیص نفوذ قدرت کشف و تشخیص نفوذهای از قبل تعریف نشده را داشته باشند، به نوعی هوشمندی نیاز دارند [2]. در این حالت، این سیستم‌ها قابلیت یادگیری دارند و می‌توانند بر روی بسته‌های وارد شده به شبکه تحلیل انجام داده و کاربران عادی و غیر عادی را تشخیص دهند. از جمله روش‌های هوشمند متداول که امروزه مورد استفاده قرار می‌گیرند: شبکه‌های عصبی؛ منطق فازی؛ تکنیک‌های داده کاوی و الگوریتم ژنتیک می‌باشند.


2- پیشینه سیستم‌های تشخیص نفوذ

امنیت در شبکه‌های کامپیوتری یکی از چالش‌های اساسی دنیای امروز است در طی سال‌های مختلف لایه‌های مختلف برای جلوگیری از ورود حملات ایجاد شده که در این بین سهم سیستم‌های تشخیص نفوذ چشمگیر بوده است، به طوری که تا قبل از سال

1980 روال کار سیستم های تشخیص نفوذ به صورت دستی انجام می شد بگونه ای که یک فرآیند به صورت دوره ای و زمانبندی شده وقایع رخ داده شده در سیستم را ثبت می کرد که به این فرآیند ثبت ممیزی گفته می شد، زمان نی که یک حمله از جانب مهاجمان انجام می شد مدیر سیستم می توانست با مراجعه به ممیزی سیستم کارهایی از قبیل: ترمیم داده های آسیب دیده، کشف محل نفوذ، بازسازی وقایع سیستم، زمان و تاریخ رخداد و همچنین نوع رویداد یا حادثه را انجام بدهد [1، 3]. ممیزی سیستم ها با اهداف مختلف ممکن است صورت پذیرد، از جمله کنترل فعالیت های افراد دارای شناسه در سیستم، تشخیص خرابی ها، تعیین و تشخیص مشکلات سیستم و نواحی رخداد آنها و تشخیص استفاده های ناصحیح یا غیر مجاز از سیستم. یکی از معایب ممیزی این بود که عملیات تولید و ثبت رویدادهای سیستم زمان بر بود و در بیشتر مواقع نمی توانست اطلاعاتی دقیق از تشخیص وقوع حمله به مدیر سیستم بدهد [4]. اما سیر تکامل سیستم های تشخیص نفوذ با افزایش سرعت، اندازه و تعداد کامپیوترها بعد از سال 1970، اهمیت امنیت سیستم های کامپیوتری افزایش یافت و با توجه به افزایش حجم داده های ذخیره شده، بحث خودکارسازی دنباله ممیزی از سال 1980 توسط اندرسون شروع شد، که با خودکار سازی ثبت رویدادها سرعت عملیات تشخیص را تسریع کرد، که به دنبال آن چندین سیستم تشخیص نفوذ مثل IDES MIDAS, Haystack, مطرح شدند [5].

1-2- سیستم تشخیص نفوذ از لحاظ منبع داده

با توجه به گسترش شبکه های کامپیوتری منابع اطلاعاتی نیز گسترش یافتند و زمان تحلیل آن ها طولانی تر و پیچیده تر شده است، سیستم های تشخیص نفوذ برای اینکه قادر به تشخیص یک حمله باشند به یک مجموعه داده برای مطابقت حملات با آن نیاز دارند یا به طور کلی هر سیستم مبتنی بر پردازش داده برای انجام عملیات خود به منابع اطلاعاتی برای ردگیری اهداف خود نیاز دارد، بنابراین یکی از نیازهای اولیه سیستم های تشخیص نفوذ بدست آوردن منابع اطلاعاتی است که متناسب با نوع سیستم تشخیص نفوذ تشخیص حمله یا جلوگیری از حمله ممکن است متفاوت باشد [6، 7]. در شکل (1) محل استقرار هر یک از روش ها قابل مشاهده است، سیستم های تشخیص نفوذ از لحاظ تامین کننده منابع اطلاعاتی به سه دسته تقسیم می شوند:



شکل (1): محل استقرار روش های سیستم تشخیص نفوذ

1-1-2- سیستم های تشخیص نفوذ مبتنی بر میزبان

از زمان مطرح شدن سیستم های تشخیص نفوذ تا سال 1990 سیستم های تشخیص تهاجم به طور عمده، مبتنی بر میزبان بودند که تحلیل آنها منحصراً بر اساس داده های حاصل از دنباله های میزبان سیستم عامل یا منابع اطلاعاتی میزبان گرای دیگر بود. سیستم های تشخیصی مبتنی بر میزبان وظیفه نظارت بر اتفاقات رخ داده شده بروی میزبان را برعهده دارند که این نظارت با جستجو کردن در فایل های سیستمی انجام می شود و با این کار هر گونه تغییرات ایجاد شده در آن ها توسط نفوذگران را پیدا می کند [8]. منظور از نظارت هر مکانیزم جمع آوری اطلاعات است که توسط سیستم تشخیص نفوذ بکار می رود. سیستم های تشخیص نفوذی که

از منابع اطلاعاتی مبتنی بر میزبان بهره می گیرند، روی اطلاعات جمع آوری شده از داخل یک سیستم (میزبان) عمل می نمایند [9].

2-1-2- سیستم های تشخیص نفوذ مبتنی بر شبکه

روال کار سیستم های تشخیصی مبتنی بر شبکه با کار کردن مستقیم بروی ترافیک شبکه انجام می شود ، با توجه به اینکه یکی از منابع مهم اطلاعاتی این سیستم ها ترافیک شبکه است بنابراین قادر به استفاده از بسته های ترافیک موجود بروی یک بخش بعنوان داده های خود می باشد که این کار با قرار دادن کارت واسط شبکه در مد تصادفی صورت می پذیرد ، مد تصادفی حالتی است که در آن کارت شبکه بگونه ای تنظیم گردد که برای کل ترافیک شبکه وقفه تولید نماید [11]. یکی از مهم ترین مزیت های این روش نسبت به روش قبلی این است که هزینه نظارت بر منابع اطلاعاتی خیلی کم است چرا که نظارت می تواند به سادگی با خواندن بسته هایی که در بخشی از شبکه جابجا می شوند، صورت پذیرد، بدون آنکه این نظارت تأثیر بر کارایی دیگر سیستم های موجود در شبکه داشته باشد، به همین دلیل اضافه کردن یک سیستم تشخیص تهاجم مبتنی بر شبکه، به یک شبکه موجود با کمترین تغییرات در آن شبکه ممکن می باشد. همچنین یکی از مهم ترین معایب این روش این است که سیستم های تشخیص تهاجم مبتنی بر شبکه با وجود سادگی و قدرتشان، معمولاً نمی توانند در شبکه های مدرن سوئیچ کار کنند، چرا که سوئیچ ها، اتصالات بین میزبان ها را از هم مجزا می سازند به طوری که یک میزبان فقط بتواند ترافیکی که به مقصد آن آدرس دهی شده را ببیند [10].

2-1-3- سیستم های تشخیص نفوذ ترکیبی

سیستم تشخیص نفوذ ترکیبی که گاهی توزیع شده گفته می شود از ترکیب دو روش قبلی بهره می برد بگونه ای که سطح امنیت و انعطاف پذیری بیشتری را بدنبال خواهد داشت، که این توزیع شدگی نه تنها در جمع آوری اطلاعات بلکه در تحلیل داده ها نیز استفاده می گردد [11]. از خصوصیات مهم این روش امکان ردیابی کاربر در شبکه تحت نظارت است، که با توجه به دشوار بودن ردیابی کاربران و فایل های رد و بدل شده بین آنها در یک شبکه بزرگ ، قابلیت مهمی به شمار می رود، بدین ترتیب تشخیص و جلوگیری از حمله های چند نفره و توزیع شده، می تواند به صورت کارا توسط این سیستم صورت پذیرد. برای بهبود کارایی این روش دو تکنیک وجود دارد. الف: تقسیم ترافیک: این روش بیشتر براساس جریان های داده ای و سیاست های امنیتی و ساختار IDS کار می کند. ب: متعادل کردن بار: در هر زمان مقدار بار مناسبی برای هر یک از حسگرها در نظر می گیرد، به نحوی که از ظرفیت سیستم به بطور بهینه استفاده شود [1].

این روش بدلیل ترکیب دو روش قبلی پیچیدگی زیادی را دارا می باشد. البته کارایی و دقت این روش در تشخیص حمله از دو روش قبلی بالاتر است.

2-2- سیستم تشخیص نفوذ از لحاظ استراتژی تحلیل

در تحلیل اطلاعات نفوذگر ، مسأله اصلی آن است که چه واقعه ای در سیستم در حال انجام است و چه فعالیت و یا واقعه ای باید مورد توجه قرار گیرد. قاعدتاً در سیستم های تشخیص تهاجم، وقایعی که نشانی از حمله و یا تهاجم به سیستم مورد حفاظت را دارند، باید در تحلیل مورد توجه قرار گیرند [1]. به این ترتیب در این قسمت سعی داریم دو روش تحلیل و تشخیص تهاجم، یعنی روش های تشخیص سوء استفاده و تشخیص ناهنجاری را معرفی شود [12]. باید توجه داشت که هر دو روش فوق ، سعی بر این دارند که به گونه ای وقایعی خاص و مشکوک را که نشانی از تهاجم و حمله را در خود دارا می باشند، مشخص نمایند :

2-2-1- تشخیص نفوذ مبتنی بر سوء استفاده

در سیستم‌های تشخیص تهاجمی که از روش سوء استفاده بهره می‌برند، در همان ابتدای امر تعریف دقیقی از تهاجم‌های ممکن، به سیستم ارائه می‌گردد و پس از آن سیستم تشخیص تهاجم با نگریستن به وقایع رخ داده در سیستم مورد حفاظت، در صورت مشاهده یک امضاء و یا الگوی تهاجمی مطابق با الگوها یا امضاهای از قبل تعریف شده، تهاجم را تشخیص و تولید اخطار می‌نماید. الگوهای تهاجم شامل ویژگی‌ها، شرایط، ترتیب و روابط بین فعالیت‌هایی هستند که منجر به نفوذ و یا سوء استفاده می‌گردند [13].

پس بنابراین باید یک پایگاه دانشی از این الگوها یا امضاهای تهاجم در سیستم ایجاد گردد و بر اساس آن به تحلیل وقایع و تشخیص سوء استفاده پرداخته شود. یکی از مزایای عمده این روش این است که حملات شناخته شده (حملاتی که در بانک اطلاعاتی ثبت شده است) به طور مطمئن و کارا تشخیص داده می‌شوند، البته یک عیب بزرگ دارند آن این است که قادر به تشخیص حملات ناشناخته و جدید نیستند [8].

2-2-2- تشخیص نفوذ مبتنی بر ناهنجاری

در یک سیستم، رفتارهای کاربران و یا برنامه‌هایی که از سیستم استفاده می‌نمایند را می‌توان به دو دسته رفتارهای هنجار و رفتارهای ناهنجار تقسیم نمود. آنچه که در سیستم تشخیص سوء استفاده مورد توجه قرار گرفته است، بخشی از مجموعه رفتارهای ناهنجار می‌باشد که همان حمله‌ها و تهاجم‌های شناخته شده است. بدین ترتیب به علت عدم شناخت حمله‌های جدید که بخش دیگر از این مجموعه رفتارهای ناهنجار را تشکیل می‌دهند، بنابراین تشخیص حمله‌های جدید و ناشناخته توسط سیستم‌های تشخیص سوء استفاده امکان پذیر نخواهد بود.

برای رفع نقص فوق در سیستم‌های تشخیص سوء استفاده، سیستم‌های تشخیص ناهنجاری با این ایده مطرح شدند که تمام فعالیت‌های تهاجمی لزوماً فعالیت‌هایی ناهنجار در سیستم هستند، پس اگر مجموعه رفتارهای هنجار را در یک سیستم شناسایی شوند، می‌توان هرگونه تخطی از آن به عنوان رفتاری ناهنجار و احتمالاً رفتاری تهاجمی تشخیص داده شود [14]. بنابراین در این سیستم ابتدا نمایه‌هایی از رفتارهای نرمال (سیستم، شبکه و یا کاربران آنها) تولید می‌شود و سپس رفتارهای اتفاق افتاده و واقعی با رفتارهای مورد انتظار و پیش بینی شده در نمایه‌های نرمال مقایسه می‌شود، که در صورت انحراف از این نمایه‌های نرمال، به عنوان یک رفتار ناهنجار و تهاجمی تشخیص داده می‌شود، هرچند ممکن است این سیستم‌ها بعضی رفتارهای نرمال را به عنوان حمله شناسایی نمایند، اما قادر به تشخیص حملات ناشناخته هستند [13].

یکی از مزیت‌های عمده این روش قابلیت تشخیص حملات جدید و ناشناخته و همچنین گونه‌های تغییر یافته حمله‌های شناخته شده می‌باشد، بدون آنکه سیستم از قبل دانشی راجع به جزئیات آنها داشته باشد [8]. البته این سیستم معایبی نیز دارد که می‌توان به هزینه ثبت و بروز رسانی رفتارهای نرمال که دارای حجم قابل توجهی هستند و همچنین تعداد زیاد هشدارهای مثبت و منفی نادرست که ناشی از رفتارهای غیر قابل پیش‌بینی کاربران یا شبکه می‌باشد اشاره کرد.

2-2-3- تشخیص نفوذ مبتنی بر نمایه

این روش براساس نیازهای کاربر، نمایه‌ها را برای پروتکل‌های خاص گسترش می‌دهد. البته هنوز به صورت همه جانبه مورد استفاده قرار نگرفته است و کاربردش بیشتر در IPv6 است، معمولاً مدل‌هایی که در این روش برای پروتکل‌های شبکه استفاده می‌شوند براساس استانداردهای بین‌المللی مانند استانداردهای موسسه IETF تعریف می‌شوند. با استفاده از این روش می‌توان ناهنجاری‌های بالقوه‌ای از جمله تغییرات در طول دستورات، مقادیر حداقل و حداکثر برای صفات و توالی غیر منتظره‌ای از دستورات که توسط سیستم‌های تشخیصی مبتنی بر امضا و مبتنی بر ناهنجاری قابل تشخیص نیستند را به راحتی ردیابی کرد. اما یکی از چالش‌های عمده این روش ترافیک‌های مخربی است که ممکن است با استفاده از این روش به درستی تشخیص داده نشوند [15]. در

جدول (1) به طور خلاصه مزایا و معایب هر کدام از روش‌ها بیان شده است.

جدول (1): مزایا و معایب روش‌های مورد استفاده در سیستم تشخیص نفوذ از لحاظ استراتژی تحلیل

مکانیزم مورد استفاده	مزیت	عیب
مبتنی بر دانش (امضا)	۱- موثرترین روش برای شناسایی حملات از پیش شناخته شده است. ۲- واپستگی خیلی کم به سیستم عامل	۱- ناتوانی در تشخیص حملات ناشناخته ۲- بروز نگرانی داشتن امضاها و الگوها مشکل است
مبتنی بر رفتار (ناهنجاری)	۱- توانایی تشخیص حملات ناشناخته ۲- وابستگی خیلی کم به سیستم عامل	۱- از دقت تشخیص پایینی برخوردار است چون وقایع همواره در حال تغییراند و ثابت نیستند. ۲- مقرون به صرفه نیست
مبتنی بر نمایه (پروتکل)	۱- شناسایی حالت پروتکل‌ها ۲- توانایی تشخیص توالی دستورات غیر منتظره	۱- ناسازگاری با برخی سیستم‌عامل‌های اختصاصی ۲- نیاز به منابع قابل توجه برای شناسایی حالت پروتکل‌ها ۳- مشکل تشخیص ترافیک‌های مخرب

3- یادگیری ماشین

در حالت کلی و عمومی یادگیری ماشین یعنی اینکه چگونه می‌توان برنامه‌ای نوشت که از طریق تجربه یادگیری کرده و عملکرد خود را بهتر کند. یکی از تعاریف یادگیری ماشینی آنطور که از سوی تام میشل، دانشیار دانشگاه کارنگی ملون ارائه گردید بدین شرح است: نوعی برنامه کامپیوتری که با توجه به برخی وظایف گروه T و عملکرد P، تجربه E را شکل می‌دهد، اگر عملکرد آن در گروه وظایف T آنطور که توسط P اندازه‌گیری شده با تجربه E بهبود پیدا کند. یادگیری ماشین به عنوان یکی از شاخه‌های وسیع و پرکاربرد هوش مصنوعی، به تنظیم و اکتشاف شیوه‌ها و الگوریتم‌هایی می‌پردازد که بر اساس آنها رایانه‌ها و سامانه‌ها توانایی تعلیم و یادگیری پیدا می‌کنند. هدف یادگیری ماشین این است که کامپیوتر (در کلی‌ترین مفهوم آن) بتواند به تدریج و با افزایش داده‌ها کارایی بهتری در انجام وظیفه مورد نظر پیدا کند. گستره این وظیفه می‌تواند از تشخیص خودکار چهره با دیدن چند نمونه از چهره مورد نظر تا فراگیری شیوه گام برداری روبات‌های دوبا با دریافت سیگنال پاداش و تنبیه باشد [16، 17].

3-1- انواع روش‌های یادگیری ماشین

روش‌های یادگیری ماشین براساس قواعد و منابعی که برای بهبود عملکرد خود استفاده می‌کنند به سه دسته مختلف تقسیم می‌شوند [18].

3-1-1. یادگیری نظارت شده

در این نوع یادگیری سیستم باید قبل از شروع به فعالیت تعلیم داده شود به عبارتی سیستم برای ادامه کار خود نیاز به یک منبع دانش دارد. در این روش هم ورودی و هم خروجی برای سیستم مورد نظر مشخص است یعنی به سیستم باید فهمانده شود که به ازای

چه ورودی، کدام خروجی را فراخوانی کند. از مزایای این روش سرعت بالا در اجرای فرایندها می باشد و از معایب این روش زمان یادگیری است چراکه سیستم باید برای اجرای هر کاری ابتدا آموزش های لازم را دریافت سپس فعالیت های خود را آغاز کند [19].

3-1-2. یادگیری نیمه نظارتی

در این نوع یادگیری تقریباً مشابه روش قبلی است اما به طور مستقیم ورودی و خروجی در اختیار سیستم قرار داده نمی شود بلکه به صورت غیر مستقیم آن ها را در قالب سیگنال های صحیح و خطا یا اصطلاحاً تنبیه و پاداش به سیستم تحویل می شود. به عبارتی یادگیری نیمه نظارتی که به یادگیری تقویتی نیز مشهور است مدلی برای مسائلی از این قبیل فراهم می آورد. در یادگیری تقویتی، سیستم تلاش می کند تا تقابلات خود با یک محیط پویا را از طریق آزمون و خطا بهینه نماید. یادگیری تقویتی مسئله ای است که یک عامل که می بایست رفتار خود را از طریق تعاملات آزمون و خطا با یک محیط پویا فرا گیرد، با آن مواجه است. در یادگیری تقویتی، هیچ نوع زوج ورودی- خروجی ارائه نمی شود. به جای آن، پس از اتخاذ یک عمل، حالت بعدی و پاداش بلافاصله به عامل ارائه می شود. هدف اولیه برنامه ریزی عامل ها با استفاده از تنبیه و تشویق است بدون آنکه ذکر از چگونگی انجام وظیفه آن ها شود. یک مثال خوب برای این نوع یادگیری انجام بازی است. اگر ماشین برنده بازی شود، سپس از نتیجه کار برای تقویت حرکات آخر خود در حین بازی بهره می گیرد [20].

3-1-3. یادگیری بدون نظارت

روش های یادگیری ماشین از نوع نظارت نشده خیلی پرکاربرد هستند و نسبت به دو نوع قبلی رواج بیشتری دارند. روش کار به این صورت است که هیچ ورودی و خروجی به سیستم داده نمی شود یعنی سیستم به اصطلاح به صورت خودمختار عمل می کند و هیچ ناظری برای آن ها وجود ندارد، برخلاف دو نوع قبلی که تعیین خروجی به نوعی وابسته به ورودی بود، اما در اینجا هیچ آموزش و تعلیمی در اختیار سیستم قرار داده نمی شود، بلکه سیستم خود به مرور زمان یاد می گیرد و خود را با شرایط وفق می دهد، به عبارتی این نوع یادگیری، زمانی رخ می دهد که ماشین با استفاده از داده هایی آموزش می بیند که هیچگونه برچسب گذاری روی آنها انجام نشده است. در این روش، هرگز به الگوریتم یادگیری گفته نمی شود که داده ها نمایانگر چه هستند. نکته کلیدی در مورد یادگیری نظارت نشده آن است که پس از پردازش اطلاعات بدون برچسب، تنها کافی است که یک نمونه از داده های برچسب گذاری شده در اختیار الگوریتم یادگیری قرار داده شود تا کارایی کامل پیدا کند. از مزایای این روش این است که هیچ نیازی به آموزش ابتدایی سیستم نیست که همین باعث محبوبیت این نوع سیستم یادگیری شده است. از معایب این روش این است که سیستم یادگیری باید فرایندهای بدون برچسب زیادی را اجرا کند تا بتواند از آن ها الگوبرداری کند و با اجرای تعداد کمی فرآیند نمی تواند نتیجه خاصی از آن بدست آورد [19، 20].

4- روش پیشنهادی

در این قسمت قبل از پرداختن به مساله، اهمیت حل این مساله بیان شده و سپس به راه حل مساله پرداخته می شود.

4-1- اهمیت حل این مساله

در زیر تعدادی موارد برای مساله تشخیص نفوذ جهت حل مساله بیان می شود که نشانگر اهمیت این موضوع در سیستم های مورد حمله واقع شده می باشد.

1. بهبود وضعیت امنیتی: با افزایش دقت و سازگاری تشخیص نفوذ، سازمان ها می توانند وضعیت کلی امنیت سایبری خود را به طور قابل توجهی بهبود بخشند.

2. کاهش هزینه: تشخیص دقیق تر به معنای کاهش مثبت کاذب، کاهش زمان و منابع صرف شده برای بررسی موارد غیرتهدید است.
3. زمان پاسخ سریعتر: بهبود قابلیت های تشخیص بلادرنگ امکان پاسخ سریعتر به تهدیدات واقعی را فراهم می کند و به طور بالقوه آسیب ناشی از حملات موفقیت آمیز را به حداقل می رساند.
4. تطبیق پذیری با تهدیدات جدید: از آنجایی که تهدیدات سایبری به سرعت در حال تکامل هستند، داشتن سیستمی که بتواند با الگوهای حمله جدید بدون به روز رسانی دستی دائمی سازگار شود بسیار ارزشمند است.
5. بهینه سازی منابع: با کاهش مثبت کاذب و بهبود کارایی، تیم های امنیتی می توانند تلاش های خود را بر روی تهدیدات واقعی، بهینه سازی منابع انسانی و محاسباتی متمرکز کنند.
6. انطباق و مقررات: بسیاری از صنایع دارای مقررات سختگیرانه امنیت سایبری هستند. IDS پیشرفته می تواند به سازمان ها کمک کند تا این الزامات انطباق را برآورده کنند و از آنها فراتر روند.
7. محافظت از داده های حساس: با افزایش ارزش داده ها، محافظت در برابر نفوذهایی که می تواند منجر به نقض داده ها شود بیش از هر زمان دیگری مهم است.
8. حفظ اعتماد: برای کسب و کارها، حفظ تدابیر امنیتی قوی برای حفظ اعتماد مشتری و حفظ شهرت بسیار مهم است.

2-4- اهداف حل این مساله

- این پژوهش برای سیستم تشخیص نفوذ با استفاده از یادگیری ماشین اهداف زیر را دنبال می کند
- توسعه یک سیستم دقیق: ایجاد یک سیستم مبتنی بر یادگیری ماشین که بتواند به طور دقیق بین ترافیک عادی شبکه و انواع مختلف نفوذ تمایز قائل شود.
 - مقایسه الگوریتم های یادگیری ماشین: ارزیابی و مقایسه عملکرد الگوریتم های مختلف یادگیری ماشین در زمینه تشخیص نفوذ.
 - بهینه سازی عملکرد: تنظیم دقیق الگوریتم های انتخاب شده برای دستیابی به بهترین تعادل ممکن بین دقت تشخیص و کارایی محاسباتی.
 - مدیریت داده های نامتعادل: رسیدگی به چالش مجموعه داده های نامتعادل، که در آن موارد ترافیک عادی به طور قابل توجهی از نمونه های نفوذ بیشتر است.
 - تشخیص بیدرنگ: توسعه سیستمی که قادر به تصمیم گیری سریع برای فعال کردن تشخیص نفوذ در زمان واقعی یا تقریباً واقعی باشد.
 - تطبیق پذیری: ایجاد چارچوبی که به راحتی بتوان آن را به روز کرد تا انواع جدیدی از حملات را در زمان ظهور شناسایی کند.
 - حداقل رساندن مثبت های کاذب: برای جلوگیری از هشدارها و اقدامات غیر ضروری، میزان مثبت های کاذب را کاهش دهیم.
 - تفسیرپذیری: اطمینان از تفسیرپذیری و توضیح تصمیمات مدل برای تحلیل گران امنیت

3-4- رویکرد روش پیشنهادی

برای روش پیشنهادی از مجموعه داده PANDAS استفاده شده است. این مجموعه داده شامل چندین ویژگی است که ترافیک شبکه را نشان می دهد و هر نمونه به عنوان معمولی یا یک نوع حمله برچسب گذاری می شود. در ابتدا این مجموعه داده از لحاظ ویژگی ها کاوش شده و براساس این خصوصیات، برای درک تعادل بین نمونه های عادی و غیرعادی بین این دو کلاس توزیع شده اند. در این قسمت موارد تکراری و از دست رفته نیز در نظر گرفته شده و کنترل می شود. در مرحله بعد، متغیرهای طبقه بندی شده با استفاده از Label Encoding برای تبدیل آنها به یک قالب قابل خواندن توسط ماشین رمزگذاری گردیده و ویژگی های بازگشتی (RFE) با RandomForestClassifier برای انتخاب 10 ویژگی مهم برتر، کاهش ابعاد و به طور بالقوه بهبود عملکرد حذف گردیده است. در این مرحله، ویژگی های انتخاب شده، با استفاده از StandardScaler برای اطمینان مشارکت همه ویژگی ها به طور یکسان در فرآیند آموزش مدل، مقیاس بندی می گردد و داده ها به مجموعه های آموزشی (70٪) و آزمایشی (30٪) برای ارزیابی داده های دیده نشده تقسیم بندی می شوند. سپس برای انتخاب مدل و آموزش از الگوریتم های یادگیری ماشین متعدد مانند رگرسیون لجستیک، (KNN) و درخت تصمیم و همچنین از Optuna برای تنظیم فرایارمتر مدل های KNN و Decision Tree برای بهینه سازی عملکرد آنها استفاده می شود.

1-3-4- چالش های این پژوهش

انجام این پژوهش با چالش هایی روبرو است. یکی از این چالش ها، انتخاب مهمترین ویژگی ها برای تشخیص نفوذ است. از بین 41 ویژگی در مجموعه داده با استفاده از Recursive Feature Elimination در پایتون بر این مشکل غلبه می شود. تنظیم پارامترهای مختلف برای انجام مدل ها، مخصوصاً KNN و Decision Tree نیاز به منابع محاسباتی و زمان زیادی دارد که با استفاده از Hyperparameter Tuning انجام می شود. برای مدیریت ویژگی های طبقه بندی شده و پیوسته، نیاز به پیش پردازش مناسب برای هر نوع است. برای کاهش خطر بیش برازش از تکنیک های هرس کردن و اعتبار سنجی متقابل استفاده شده است.

5- ارزیابی مدل:

این پژوهش با استفاده از زبان برنامه نویسی پایتون و کتابخانه های آن نوشته شده است. پس از آموزش، مدل را بر روی یک مجموعه داده آزمایشی PANDAS تست کرده تا عملکرد آن ارزیابی شود. این ارزیابی دقت و همچنین یک گزارش طبقه بندی را ارائه می کند که شامل معیارهایی مانند دقت، یادآوری و امتیاز F1 برای هر کلاس است.

- دقت: نسبت مشاهدات مثبت پیش بینی شده صحیح به کل مثبت های پیش بینی شده می باشد.
- دقت یادآوری (RECALL): نسبت مشاهدات مثبت پیش بینی شده درست به همه مشاهدات در کلاس واقعی می باشد.

نحوه چگونگی انجام این پارامترها را در معادلات (1) و (2) مشاهده می شود.

TP مشاهدات مثبت پیش بینی شده صحیح و TF مشاهدات مثبت پیش بینی شده غلط می باشد.

FN مشاهدات منفی پیش بینی شده غلط می باشد.

$$\text{Precision} = \frac{TP}{TP+FP} \quad (1)$$

$$\text{Recall} = \frac{TP}{TP+FN} \quad (2)$$

- امتیاز $F1$: یک میانگین هارمونیک از دقت و یادآوری که نمای متعادلی از عملکرد مدل ارائه می دهد. معادله (3) این امتیاز را نشان می دهد.

$$F1 = \frac{2 * Precision * recall}{precision + recall}$$

(3)

همچنین برای اطمینان از برآوردهای عملکرد قوی، اعتبارسنجی متقابل انجام شده است. علاوه برای درک دقیق عملکرد مدل، ماتریس های سردرگمی و گزارش های طبقه بندی ایجاد شده است.


برای بهبود عملکرد مدل، انتخاب ویژگی های مورد نیاز تکرار می شود و فرآپارامترها تنظیم می شوند. از نظر دقت و کارایی محاسباتی مبادلات بین مدل های مختلف تجزیه و تحلیل می شود. در ادامه نمودارهای ارزیابی شده برای بدست آوردن هر پارامتر در هر مدل ارائه می شود.

6- مقایسه و تحلیل الگوریتم ها

6-1- دقت و دقت یادآوری

در این بخش، عملکرد سه الگوریتم یادگیری ماشین - رگرسیون لجستیک، K-Nearest Neighbors (KNN) و Decision Tree - مورد استفاده در پژوهش سیستم تشخیص نفوذ (IDS) مقایسه می شود. هر الگوریتم در هر دو مجموعه داده آموزشی و آزمایشی مورد ارزیابی قرار گرفته است و نقاط قوت و ضعف آنها از نظر دقت، توانایی تعمیم و مناسب بودن برای مجموعه داده مورد تجزیه و تحلیل قرار داده شد.

شکل (2) مقایسه الگوریتم ها را براساس دقت و دقت یادآوری نشان می دهد.



شکل (2): مقایسه الگوریتم ها براساس دقت و دقت یادآوری

رگرسیون لجستیک

- نمای کلی:

رگرسیون لجستیک یک مدل خطی است که احتمال یک متغیر هدف طبقه بندی شده را پیش بینی می کند. در این پژوهش، از آن برای طبقه بندی ترافیک شبکه به کلاس های عادی و غیرعادی استفاده شده است. رگرسیون لجستیک برای تفسیر ساده است، و آن

را برای برنامه‌هایی که نیاز به توضیح ساده نتایج دارند، ایده آل می‌کند.

• عملکرد:

امتیاز آموزشی: 92.88%

امتیاز آزمایشی: 92.31%

• تحلیل:

رگرسیون لجستیک عملکرد نسبتاً خوبی را با دقت تقریباً 92.31 درصد در داده‌های آزمایش به دست آورد. این نشان می‌دهد که مدل توانسته است به خوبی از داده‌های آموزشی به داده‌های دیده نشده تعمیم دهد. با این حال، عملکرد کمتر آن در مقایسه با سایر الگوریتم‌ها نشان می‌دهد که رابطه بین ویژگی‌ها و متغیر هدف ممکن است کاملاً خطی نباشد. رگرسیون لجستیک، به دلیل ماهیت خود، در تلاش است تا الگوهای پیچیده یا غیرخطی را در داده‌ها ثبت کند، و در این زمینه که روابط غیرخطی وجود دارد، کارایی آن را کاهش می‌دهد.

✓ نقاط قوت این الگوریتم

▪ پیاده سازی و تفسیر ساده است.

▪ برای داده‌های قابل جداسازی خطی به خوبی کار می‌کند.

▪ از نظر محاسباتی کارآمد است و به حداقل حافظه نیاز دارد.

✓ محدودیت‌های این الگوریتم

▪ تلاش برای مدل سازی روابط غیر خطی.

▪ دقت کمتر در مقایسه با مدل‌های پیچیده تر مانند Decision Trees و KNN.

K نزدیکترین همسایه (KNN)

• نمای کلی:

KNN یک الگوریتم یادگیری مبتنی بر نمونه است که نقاط داده را بر اساس کلاس‌های نزدیکترین همسایگان آنها در فضای ویژگی طبقه بندی می‌کند. این یک مدل ناپارامتریک است، به این معنی که مفروضات کمتری در مورد توزیع داده‌های اساسی ایجاد می‌کند.

• عملکرد:

امتیاز آموزشی: 98.73%

امتیاز آزمایشی: 98.31%

• تحلیل:

مدل KNN عملکرد فوق‌العاده‌ای داشت و به دقت تست 98.31 درصد دست یافت. این نشان می‌دهد که این مدل قادر به ثبت الگوهای پیچیده در داده‌ها بوده و آن را برای این کار بسیار مؤثر می‌سازد. عملکرد KNN نشان می‌دهد که مجموعه داده شامل مناطقی است که نمونه‌ها به شدت خوشه‌بندی شده‌اند، و به مدل اجازه می‌دهد تا نقاط داده را به‌طور دقیق بر اساس همسایگان خود طبقه‌بندی کند.

با این حال، KNN دارای اشکالات محاسباتی خاصی است. از آنجایی که الگوریتم کل مجموعه آموزشی را ذخیره می‌کند، حافظه فشرده است، و می‌تواند از نظر محاسباتی در مرحله پیش‌بینی، به ویژه با مجموعه داده‌های بزرگ، گران باشد. در مورد ما، دقت نشان می‌دهد که عملکرد بالای مدل بر این چالش‌ها غلبه کرده است.

✓ نقاط قوت الگوریتم

- قادر به مدل سازی روابط غیر خطی.
- برای مجموعه‌های داده با خوشه‌ها یا الگوهای کاملاً تعریف شده مؤثر است.
- دقت بالا در هر دو مرحله تمرین و تست.
- ✓ محدودیت های الگوریتم
- از نظر محاسباتی گران است، به خصوص با مجموعه داده های بزرگ.
- حساس به انتخاب 'k' (تعداد همسایگان).
- برای جلوگیری از سوگیری نسبت به متغیرهایی با محدوده بزرگتر، به مقیاس بندی ویژگی ها نیاز دارد.

درخت تصمیم

- نمای کلی الگوریتم

الگوریتم Decision Tree یک ساختار درخت مانند می‌سازد که در آن هر گره داخلی یک تصمیم در مورد یک ویژگی را نشان می‌دهد و هر گره برگ نشان دهنده یک برچسب کلاس است. بسیار قابل تفسیر است و می‌تواند داده های مقوله ای و عددی را به طور مؤثر اداره کند.

- عملکرد:

امتیاز آموزشی: 100٪

امتیاز آزمایشی: 99.51٪

- تحلیل:

مدل درخت تصمیم بهتر از رگرسیون لجستیک و KNN عمل کرد و به دقت آموزشی 100٪ و دقت تست تقریباً کامل 99.51٪ دست یافت. این نشان می‌دهد که این مدل تمام نمونه‌های آموزشی را کاملاً طبقه‌بندی می‌کند، اما در داده‌های آزمایشی دیده نشده نیز عملکرد قابل توجهی دارد.

علی‌رغم دقت فوق‌العاده، عملکرد بی‌نقص مدل در داده‌های آموزشی، نگرانی‌هایی را در مورد اضافه‌برازش احتمالی ایجاد می‌کند. برازش بیش از حد زمانی اتفاق می‌افتد که مدل داده‌های آموزشی را به خاطر می‌سپارد و منجر به تعمیم ضعیف به داده‌های جدید می‌شود. با این حال، با توجه به اینکه دقت تست بالا باقی می‌ماند، بیش از حد برازش حداقل است، و مدل به خوبی برای مجموعه داده ما مناسب است. توانایی درخت تصمیم برای ثبت روابط و تعاملات غیرخطی بین ویژگی‌ها، آن را برای این کار بسیار مؤثر می‌سازد.


✓ نقاط قوت الگوریتم

- ویژگی های دسته بندی و عددی را کنترل می‌کند.
- روابط غیر خطی را به طور مؤثر مدل می‌کند.
- تفسیرپذیری واضحی را ارائه می‌دهد که برای درک اهمیت ویژگی ارزشمند است.

- عملکرد بالا، با دقت عالی در هر دو مجموعه تمرین و تست.
- ✓ محدودیت های الگوریتم
- مستعد بیش از حد برازش، به خصوص اگر هرس یا منظم نشده باشد.
- حساس به تغییرات کوچک در داده ها، که می تواند منجر به یک ساختار درختی کاملاً متفاوت شود.
- بازده محاسباتی کمتر در مقایسه با مدل های ساده تر مانند رگرسیون لجستیک.

6-2- امتیاز F1

هر سه مدل بر اساس دقت و توانایی آنها برای تعمیم از داده های آموزشی به داده های آزمون ارزیابی می شود. در شکل (3) مقایسه ای از عملکرد آنها آورده شده است:



شکل(3): مقایسه ای از عملکرد الگوریتم ها براساس امتیاز F1

بهترین مدل از نظر عملکرد: درخت تصمیم با دقت آزمون 99.51 درصد به بالاترین دقت دست یافت. این باعث می شود که در مقایسه بهترین مدل باشد.

KNN: مدل KNN نیز با دقت آزمایش 98.31 درصد عملکرد فوق العاده ای داشت. این در رتبه دوم نسبت به Decision Tree قرار دارد و تعادل خوبی بین پیچیدگی و عملکرد ارائه می دهد.

رگرسیون لجستیک: اگرچه رگرسیون لجستیک عملکرد خوبی دارد، اما با دقت 92.31 درصد، هم توسط درخت تصمیم و هم توسط KNN بهتر عمل کرد. سادگی آن ممکن است اثربخشی آن را در گرفتن روابط غیر خطی در مجموعه داده محدود کرده باشد.

مقایسه عملکرد:

در جدول (2) مقایسات عملکرد این سه الگوریتم بصورت خلاصه نشان داده شده است.

جدول (2): مقایسات الگوریتم‌ها

مدل	train score	test score
نزدیکترین همسایه ها	0.983064	0.987297
رگرسیون لجستیک	0.928774	0.923128
درخت تصمیم	1.000000	0.995105

3-6- نتایج تایید متقابل:

- KNN: دقت 98.45 ± 0.48 درصد، فراخوان 98.24 ± 0.54 درصد

- رگرسیون لجستیک: دقت 91.35 ± 0.57 درصد، فراخوان 95.72 ± 0.67 درصد

- درخت تصمیم: دقت 99.51 ± 0.21 درصد، فراخوان 99.51 ± 0.24 درصد

مدل درخت تصمیم بهترین عملکرد کلی را نشان داد که KNN بعد از آن نزدیکترین بود. رگرسیون لجستیک، اگرچه هنوز خوب است، از دو مدل دیگر عقب مانده است.

7- نتیجه گیری

این پژوهش پتانسیل الگوریتم‌های یادگیری ماشین را در ایجاد سیستم‌های تشخیص نفوذ موثر نشان داده است. با مقایسه مدل‌های مختلف و بهینه‌سازی عملکرد آن‌ها، یک سیستم تشخیص نفوذ ایجاد شده است که دقت بالایی در تشخیص نفوذ شبکه نشان می‌دهد.

مدل درخت تصمیم، با دقت 99.51 درصد، به عنوان بهترین عملکرد ظاهر شد و از نزدیک با مدل KNN دنبال شد. این نتایج نشان می‌دهد که رویکردهای یادگیری ماشینی می‌توانند قابلیت‌های سیستم‌های تشخیص نفوذ را به‌طور قابل توجهی افزایش دهند و دقت بهبود یافته و پتانسیل سازگاری با تهدیدات جدید را ارائه دهند. با این حال، این پژوهش همچنین ملاحظات مهمی را برای استقرار در دنیای واقعی، از جمله نیاز به تعادل دقت با کارایی محاسباتی، اطمینان از تفسیرپذیری، و طراحی برای مقیاس‌پذیری و پردازش بلادرنگ را برجسته کرد. همانطور که تهدیدات سایبری به تکامل خود ادامه می‌دهند، آینده سیستم تشخیص نفوذ در سیستم‌های سازگارتر و هوشمندتر نهفته است که می‌توانند الگوهای حمله جدید را به سرعت یاد بگیرند و به آنها پاسخ دهند. با دنبال کردن مسیرهای مشخص شده آینده، می‌توان در جهت ایجاد سیستم‌های تشخیص نفوذ قوی‌تر و مؤثرتر کار شود، که کمک قابل توجهی به حوزه امنیت سایبری خواهد کرد.

- [1] R.G. Bace, "Survey Intrusion Detection," Macmillan Technical Publishing, USA, 2000.
- [2] M. Almseidin, M. Alzubi, S. Kovacs and M. Alkasassbeh, "Evaluation of machine learning algorithms for intrusion detection system," *2017 IEEE 15th International Symposium on Intelligent Systems and Informatics (SISY)*, Subotica, Serbia, 2017, pp. 000277-000282, doi: 10.1109/SISY.2017.8080566.
- [3] T. Saranya, S. Sridevi, C. Deisy, Tran Duc Chung, M.K.A.Ahamed Khan, Performance Analysis of Machine Learning Algorithms in Intrusion Detection System: A Review, *Procedia Computer Science*, Volume 171, 2020.2020.
- [4] John Vacca, John Mallery, Scott R. Ellis, Bill Mansoor, "Computer and Information Security Handbook", copyright 2013 by Elsevier inc. all right reserved, 2013.
- [5] H.Liao, Ch.Richard Lin, Y. Lin, K.Tung " Intrusion detection system : A comprehensive review," Department of Computer Science and Information Engineering, Cheng Shiu University & Elsevier Ltd. All rights reserved 2012.
- [6] U. S. Musa, M. Chhabra, A. Ali and M. Kaur, "Intrusion Detection System using Machine Learning Techniques: A Review," *2020 International Conference on Smart Electronics and Communication (ICOSEC)*, Trichy, India, 2020, pp. 149-155, doi: 10.1109/ICOSEC49089.2020.9215333.
- [7] E. Guillen, J. Sánchez and R. Paez, "Inefficiency of IDS Static Anomaly Detectors in Real-World Networks", Engineering Systems Department, Xaverian University, Colombia, Published: 6 May 2015.
- [8] Ch. Prajka, A.Raut, "Hybrid Model For Intrusion Detection System, *International Journal Of Engineering And Computer Science* ISSN:2319-7242 Volume1 Issue 3 Dec 2012 .
- [9] I. Abrar, Z. Ayub, F. Masoodi and A. M. Bamhdi, "A Machine Learning Approach for Intrusion Detection System on NSL-KDD Dataset," *2020 International Conference on Smart Electronics and Communication (ICOSEC)*, Trichy, India, 2020, pp. 919-924, doi: 10.1109/ICOSEC49089.2020.9215232.
- [10] Amar Meryem, Bouabid EL Ouahidi, Hybrid intrusion detection system using machine learning Network Security, Volume 2020, Issue 5, 2020.
- [11] Alzahrani, Abdulsalam O., and Mohammed J. F. Alenazi. 2021. "Designing a Network Intrusion Detection System Based on Machine Learning for Software Defined Networks" *Future Internet* 13, no. 5: 111. <https://doi.org/10.3390/fi13050111>.
- [12] Kocher, G., Kumar, G. Machine learning and deep learning methods for intrusion detection systems: recent developments and challenges. *Soft Comput* 25, 9731–9763 (2021). <https://doi.org/10.1007/s00500-021-05893-0>.
- [13] Thakkar, A., Lohiya, R. A survey on intrusion detection system: feature selection, model, performance measures, application perspective, challenges, and future research directions. *Artif Intell Rev* 55, 453–563 (2022). <https://doi.org/10.1007/s10462-021-10037-9>.
- [14] B. Zaugg, "An Overview of Intrusion Detection Systems Technology and Research", Published on 19 June 2010.
- [15] T. Sproull, J. Lockwood, Distributed Intrusion Prevention in Active and Extensible Networks, In: Active Lecture Notes Networks Computer Science, Vol. 3912, pp 54-65, 2007.
- [16] Barbara, D., Goel, R., and Jajodia, "S. Mining Malicious Data Corruption with Hidden Markov Models". In Proceedings of the 16th Annual IFIP WG 11.3 Working Conference on Data and Application Security, Cambridge, England, July 2002.
- [17] Greener, J.G., Kandathil, S.M., Moffat, L. et al. A guide to machine learning for biologists. *Nat Rev Mol Cell Biol* 23, 40–55 (2022). <https://doi.org/10.1038/s41580-021-00407-0>.
- [18] A. Smola and S. Vishwanathan, "INTRODUCTION TO MACHINE LEARNING", Departments of Statistics and Computer Science Cambridge University Press 2008.
- [19] Janiesch, C., Zschech, P. & Heinrich, K. Machine learning and deep learning. *Electron Markets* 31, 685–695 (2021). <https://doi.org/10.1007/s12525-021-00475-2>.
- [20] Sarker, I.H. Machine Learning: Algorithms, Real-World Applications and Research Directions. *SN COMPUT. SCI.* 2, 160 (2021). <https://doi.org/10.1007/s42979-021-00592-x>.